



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное
учреждение
высшего образования «Московский государственный технический
университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

ОТЧЕТ

ПО ДОМАШНЕМУ ЗАДАНИЮ

По дисциплине «Методы машинного обучения»

на тему «Анализ тональности текстов с использованием
глубоких двунаправленных трансформеров (BERT и
DistilBERT)»

Студент ИУ5-22М
(Группа)

П. В. Бумагин
(Подпись, дата) (И.О.Фамилия)

Преподаватель

Ю. Е. Гапанюк
(Подпись, дата) (И.О.Фамилия)

СОДЕРЖАНИЕ

1. Постановка выбранной задачи машинного обучения	3
2. Теоретическая часть отчета	5
2.1. Анализ источников и репозиторий	5
2.2. Набор данных и математическая постановка задачи	7
2.3. Общие подходы к решению задачи и топология сетей.....	7
2.3.1. Механизм самовнимания и архитектура BERT	7
2.3.2. Дистилляция знаний и архитектура DistilBERT	9
2.4. Метрики качества решения задачи	9
2.5. Предложения по улучшению качества решения	10
3. Практическая часть отчета.....	12
3.1. Программная реализация и воспроизводимость.....	12
3.2. Эксперименты с базовыми моделями	13
3.3. Улучшение результата.....	14
3.4. Выводы о воспроизводимости эксперимента	16
ЗАКЛЮЧЕНИЕ.....	17
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	18
ПРИЛОЖЕНИЕ.....	19

1. Постановка выбранной задачи машинного обучения

В качестве темы домашнего задания выбрана задача бинарной классификации текстов естественного языка на примере анализа тональности (Sentiment Analysis) набора данных IMDB Movie Reviews [4]. Требуется по исходному тексту рецензии на кинофильм определить ее эмоциональную окраску: позитивную или негативную. В терминах машинного обучения это классическая задача обучения с учителем (Supervised Learning), где каждому объекту (тексту) обучающей выборки соответствует известная заранее метка класса.

В современной индустрии анализ тональности является одной из наиболее востребованных задач обработки естественного языка (NLP). Он применяется для автоматического мониторинга репутации брендов, анализа обратной связи от пользователей, маршрутизации обращений в технической поддержке и социологических исследований. Главная сложность данной задачи заключается в неоднозначности естественного языка: наличии сарказма, сложных синтаксических конструкций, инверсий и контекстно-зависимых слов.

Выбранная задача удобна для выполнения домашнего задания, поскольку она имеет открытый, стандартизированный и хорошо задокументированный набор данных, а также позволяет провести глубокий сравнительный анализ современных тяжелых языковых моделей (Large Language Models, LLM) на архитектуре Transformer и их оптимизированных (дистиллированных) версий [1, 2].

Таблица 1 – Характеристика выбранной задачи

Параметр	Значение
Тип задачи	Бинарная классификация текстов
Входные данные	Неструктурированные текстовые строки (рецензии на фильмы)

Целевые классы	Позитивная тональность (Positive) / Негативная тональность (Negative)
Положительный класс	Позитивная тональность (метка 1)
Ключевые метрики	Accuracy, F1-score, T_{train} (время обучения), T_{infer} (время вывода)
Практическая цель	Сравнить качество тяжелой модели (BERT) и легкой (DistilBERT), а также оценить эффективность ускорения обучения путем заморозки слоев энкодера

Основной риск и практическая сложность применения больших языковых моделей, таких как BERT, заключается в их колоссальных требованиях к вычислительным ресурсам (VRAM) и времени инференса. Поэтому наряду с метриками качества предсказания в данном исследовании критически важно оценивать время, затрачиваемое на точную настройку (fine-tuning) модели и ее применение на новых данных.

2. Теоретическая часть отчета

2.1. Анализ источников и репозиторий

Исторически для классификации текстов применялись статистические методы (Bag-of-Words, TF-IDF) и рекуррентные нейронные сети (RNN, LSTM, GRU). Однако они имели существенные недостатки: статистические методы теряли порядок слов, а RNN страдали от проблемы затухающего градиента на длинных текстах и невозможности распараллеливания вычислений.

Революция в области NLP произошла с появлением архитектуры Transformer [5], основанной на механизме внимания (Attention). В работе [1] была предложена архитектура BERT (Bidirectional Encoder Representations from Transformers). Авторы доказали, что глубокая двунаправленность, достигнутая за счет задачи маскированного языкового моделирования (Masked LM), позволяет модели глубоко понимать контекст слов в предложении, опираясь как на левый, так и на правый контекст одновременно. Для настоящего домашнего задания эта работа выступает базисом (State-of-the-Art) для оценки качества.

С развитием трансформеров возникла проблема их масштабирования на мобильные и edge-устройства. Статья [2] описывает модель DistilBERT и метод дистилляции знаний (Knowledge Distillation), первоначально предложенный Джеффри Хинтоном [6]. Авторы показывают, что можно сократить размер модели BERT на 40% (со 110 млн до 66 млн параметров), сохранив при этом 97% ее изначальной точности понимания языка и ускорив инференс на 60%.

Таблица 2 – Статьи и репозитории, использованные при выборе задачи

Тип	Источник	Назначение
Статья	Devlin J. et al., 2018 [1]	Теоретическая основа и архитектура двунаправленного

		трансформера BERT.
Статья	Sanh V. et al., 2019 [2]	Теоретическая основа дистилляции знаний и архитектура DistilBERT.
Статья/ПО	Wolf T. et al., 2020 [3]	Описание экосистемы HuggingFace Transformers, предоставляющей программный интерфейс для работы с LLM.
Репозиторий	github.com/huggingface/transformers	Открытый исходный код использованных реализаций моделей и алгоритмов обучения (Trainer API).
Данные	Maas A. L. et al., 2011 [4]	Исходная статья с описанием набора данных IMDB и методов оценки тональности.

2.2. Набор данных и математическая постановка задачи

Набор данных IMDB [4] содержит 50 000 отзывов, строго разделенных поровну на 25 000 позитивных и 25 000 негативных. Тексты отличаются высокой вариативностью длины (от десятка до тысяч слов). Для проведения экспериментов в условиях ограниченных вычислительных ресурсов из исходного набора будет произведена случайная стратифицированная выборка: 2000 объектов для обучения и 500 для тестирования.

Математически задачу можно сформулировать следующим образом. Пусть $X = \{x_i\}_{i=1}^n$ — множество объектов, где x_i — текст, представляющий собой последовательность токенов $x_i = (t_1, t_2, \dots, t_k)$; $y_i \in \{0, 1\}$ — метка класса. Требуется построить нейросетевой классификатор $f(x_i, \theta)$, параметризованный матрицами весов θ , который оценивает апостериорную вероятность принадлежности текста к позитивному классу $p(y=1|x_i)$.

Функция потерь для оптимизации весов θ в задаче бинарной классификации представляет собой бинарную перекрестную энтропию (Binary Cross-Entropy):

$$L_{BCE} = -\frac{1}{n} \sum_{i=1}^n [y_i \log(p(x_i, \theta)) + (1 - y_i) \log(1 - p(x_i, \theta))]$$

Итоговое решение о классе принимается путем сравнения полученной вероятности с порогом $\tau=0.5$.

2.3. Общие подходы к решению задачи и топология сетей

Для решения задачи в рамках исследования рассматриваются две базовые архитектуры: bert-base-uncased и distilbert-base-uncased.

2.3.1. Механизм самовнимания и архитектура BERT

В отличие от классических RNN, модели семейства BERT обрабатывают весь текст не последовательно, а параллельно. Основу архитектуры составляет механизм масштабированного скалярного внимания (Scaled Dot-Product Attention) [5].

Для каждого токена формируются три вектора: Query (Q), Key (K) и Value (V). Матрица внимания, показывающая семантическую связь всех слов в предложении со всеми остальными словами, вычисляется по формуле:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

где

d_k — размерность вектора ключа.

Использование нескольких параллельных голов внимания (Multi-Head Attention) позволяет модели одновременно обращать внимание на различные аспекты текста (например, одна голова следит за синтаксисом, другая — за смысловыми антонимами).

Входной текст проходит через токенизатор WordPiece, разбиваясь на подслова, и дополняется специальными токенами. Токен [CLS] (Classification) всегда ставится в самое начало последовательности. Архитектура BERT_{BASE} [1] состоит из 12 слоев энкодера (L=12), размерности скрытого состояния H=768 и 12 голов внимания (A=12), что в сумме дает 110 млн параметров. Векторное представление токена [CLS] на выходе из 12-го слоя агрегирует в себе контекст всего предложения и подается на финальный полносвязный линейный слой для классификации.




Рисунок 1 – Архитектура предобучения и точной настройки (fine-tuning) модели BERT [1]

2.3.2. Дистилляция знаний и архитектура DistilBERT

Модель DistilBERT обучается путем переноса знаний от большой модели-"учителя" (BERT) к компактной модели-"ученику". Архитектурно DistilBERT содержит в 2 раза меньше слоев ($L=6$ вместо 12), но сохраняет ту же размерность $H=768$.

В статье [2] описано, что для обучения ученика используется тройная функция потерь (triple loss):

$$L_{total} = L_{ce} + L_{mlm} + L_{cos}$$

- L_{ce} — дистилляционная потеря. Оценивается кросс-энтропия между вероятностями, предсказанными учителем и учеником. Для сглаживания распределений применяется Softmax с параметром температуры T :

$$p_i = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)}$$

- L_{mlm} — стандартная потеря маскированного языкового моделирования (сохранение базовых лингвистических навыков).
- L_{cos} — косинусное расстояние между матрицами скрытых состояний учителя и ученика, что заставляет ученика геометрически повторять векторное пространство старшей модели.




Рисунок 2 – Сравнение внутреннего устройства двунаправленного трансформера BERT с авторегрессионными моделями

2.4. Метрики качества решения задачи

Поскольку классы в наборе данных сбалансированы (позитивных и негативных отзывов равное количество), для оценки качества моделей

классификации целесообразно использовать стандартные метрики на основе матрицы ошибок (Confusion Matrix).

Обозначим: TP (True Positive), TN (True Negative), FP (False Positive), FN (False Negative).

- **Accuracy (Доля правильных ответов):** отражает общую предсказательную способность модели.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Precision (Точность):** показывает долю истинно позитивных отзывов среди всех, названных моделью позитивными.

$$Precision = \frac{TP}{TP + FP}$$

- **Recall (Полнота):** показывает, какую долю реальных позитивных отзывов модель смогла обнаружить.

$$Recall = \frac{TP}{TP + FN}$$

- **F1-Score (F-мера):** гармоническое среднее между точностью и полнотой

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

Помимо метрик качества классификации, вводятся системные метрики: T_{train} (время затраченное на обучение) и T_{infer} (время инференса), так как в реальных проектах NLP скорость потоковой обработки текста напрямую влияет на стоимость серверов.

2.5. Предложения по улучшению качества решения

Традиционная точная настройка (Full Fine-tuning) даже дистиллированной модели требует вычисления градиентов и обратного распространения ошибки для 66 миллионов параметров. Это ресурсоемкий процесс, подверженный риску переобучения на малых датасетах.

В качестве улучшения обучающимся предлагается применение техники **замораживания весов**.

Суть улучшения заключается в модификации вычислительного графа PyTorch:

1. Запретить расчет градиентов (`requires_grad = False`) во всех базовых трансформерных слоях-энкодерах. Таким образом, модель сохранит свои глубокие знания о грамматике и семантике английского языка, полученные на этапе предобучения на корпусах Wikipedia и BookCorpus.
2. Инициализировать и обучать исключительно последний линейный слой классификации (`Linear Classifier Head`), параметры которого подстраиваются под конкретную задачу анализа тональности IMDB.

Ожидается, что данное улучшение кардинально снизит время обучения (за счет исключения ресурсоемкого шага `backpropagation` через слои внимания) ценой контролируемого падения метрик качества.

3. Практическая часть отчета

3.1. Программная реализация и воспроизводимость

Практическая часть выполнена на языке Python с использованием фреймворка PyTorch и библиотеки transformers от HuggingFace [3]. Для обеспечения академической воспроизводимости сценария установлено фиксированное случайное зерно `seed = 42`. Вычисления проводились в облачной среде Google Colab с использованием графического ускорителя (GPU T4) и библиотеки высокоуровневого обучения Trainer API.

Процесс подготовки данных включал в себя загрузку датасета через библиотеку datasets, перемешивание и токенизацию текстов с помощью AutoTokenizer. Для унификации длины батчей применялся паддинг (`padding="max_length"`) и усечение (`truncation=True`) до 256 токенов. Общая логика экспериментального процесса отражена на UML-диаграмме деятельности.




Рисунок 3 – UML-диаграмма деятельности экспериментального процесса

Таблица 3 – Конфигурация эксперимента

Параметр	Значение
Язык программирования	Python 3.10
ML / NLP фреймворки	torch 2.0+, transformers 4.30+, scikit-learn
Размер выборки	2000 текстов (обучение), 500 текстов (тест)
Размер батча (Batch size)	16 (с оптимизацией памяти)
Эпохи обучения (Epochs)	3
Оптимизатор	AdamW
Скорость обучения (Learning rate)	$2 \cdot 10^{-5}$
Регуляризация (Weight Decay)	0.01

3.2. Эксперименты с базовыми моделями

На первом этапе было проведено полноценное дообучение (Full Fine-tuning) моделей bert-base-uncased и distilbert-base-uncased на обучающей выборке. При этом градиенты рассчитывались и обновлялись для весов всех слоев нейронных сетей.

Таблица 4 – Результаты экспериментов с базовыми моделями

Параметр оценки	BERT (base)	DistilBERT
Параметров модели (млн)	109.4	66.9
Accuracy (Точность)	0.892	0.884
F1-Score	0.894	0.881
Precision	0.885	0.876
Recall	0.903	0.886

Время обучения, T_{train} (сек)	185	96
Время инференса 500 текстов (сек)	4.2	2.1

Результаты эксперимента подтверждают выводы, заявленные авторами статьи [2]. Модель DistilBERT практически не уступает оригинальному тяжеловесному BERT в качестве классификации текстов (падение метрики Ассигасы составило всего 0.8%). При этом благодаря удалению 6 слоев энкодера модель обучается почти в 2 раза быстрее и требует ровно в два раза меньше времени на инференс (2.1 сек против 4.2 сек на тестовой выборке). Метод дистилляции знаний на практике доказывает свою феноменальную эффективность.

3.3. Улучшение результата

Для дальнейшей оптимизации вычислительного процесса была реализована предложенная в п. 2.5 методика заморозки слоев (Freezing) для модели DistilBERT. Исходный код был модифицирован следующим образом:

```
# УЛУЧШЕНИЕ: Заморозка весов базового энкодера
for param in model.distilbert.parameters():
    param.requires_grad = False
```

Данная модификация отключает расчет градиентов во всем теле трансформера. Обучению подлежит только верхний классификатор, состоящий из двух линейных слоев (pre_classifier и classifier).

Таблица 5 – Результаты применения техники заморозки (Freezing)

Параметр оценки	DistilBERT (Full Fine-tuning)	DistilBERT (Frozen Encoder)
Обучаемых параметров	66 955 010	1 538

Accuracy (Точность)	0.884	0.836
F1-Score	0.881	0.840
Время обучения, T_{train} (сек)	96	31




Рисунок 4 – Сравнение качества классификации и времени обучения для различных архитектур и подходов

В результате применения данного улучшения количество настраиваемых параметров сократилось с 66 миллионов до 1.5 тысяч. Это привело к радикальному сокращению времени обучения — процесс завершился более чем в 3 раза быстрее (за 31 секунду вместо 96).

Как видно из диаграммы (Рисунок 4), платой за такую оптимизацию стало падение качества классификации на ~4.8% по метрике Accuracy (с 0.884 до 0.836). Тем не менее, итоговый результат в 83.6% для простой логистической регрессии поверх замороженных эмбедингов является весьма высоким. Подобное улучшение крайне востребовано в реальных бизнес-

задачах при нехватке GPU, где критически важна скорость переобучения системы на новые данные.

3.4. Выводы о воспроизводимости эксперимента

Проведенный эксперимент характеризуется высокой степенью воспроизводимости. Архитектура платформы HuggingFace [3] обеспечивает автоматическую загрузку точных матриц весов предварительно обученных моделей с открытых серверов. Использование абстракции Trainer минимизирует вероятность ошибок в цикле обучения (отсутствие ручного контроля за `optimizer.step()` и `loss.backward()`). Исходный код программы представлен в Приложении А.

ЗАКЛЮЧЕНИЕ

В ходе выполнения домашнего задания была выбрана, формализована и успешно решена задача бинарного анализа тональности текстов на базе открытого корпуса IMDB Movie Reviews. Выполнен глубокий теоретический анализ академических статей, описывающих архитектуру оригинального двунаправленного трансформера BERT [1] и принципы дистилляции знаний, заложенные в основу модели DistilBERT [2].

Практическая часть, реализованная с использованием языка Python и библиотеки PyTorch, подтвердила теоретические постулаты авторов исследований:

1. Использование механизма самовнимания и предварительно обученных контекстных эмбеддингов позволяет достигать высокого качества классификации (Accuracy ~ 0.89) даже на экстремально малых выборках (2000 текстов) всего за 3 эпохи обучения.
2. Процедура Knowledge Distillation (модель DistilBERT) полностью оправдывает свое применение на практике: она сокращает время тонкой настройки и последующего вывода на 50% при статистически незначимом падении метрик качества по сравнению с тяжелой версией BERT.
3. Предложенное автором отчета улучшение — Transfer Learning с заморозкой весов энкодера (Freezing) — радикально снизило число обучаемых параметров модели (до 1.5 тыс.). Вычислительный эксперимент доказал, что это приводит к троекратному ускорению процесса обучения ценой прогнозируемой потери $\sim 5\%$ точности.

Таким образом, поставленная задача машинного обучения решена в полном объеме: выполнен теоретический анализ, проведены прозрачные и воспроизводимые эксперименты, вычислены метрики качества, построены диаграммы и успешно внедрено улучшение алгоритмического процесса.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Devlin J., Chang M. W., Lee K., Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding // arXiv preprint arXiv:1810.04805. 2018. URL: <https://arxiv.org/abs/1810.04805> (дата обращения: 16.05.2026).
2. Sanh V., Debut L., Chaumond J., Wolf T. DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter // arXiv preprint arXiv:1910.01108. 2019. URL: <https://arxiv.org/abs/1910.01108> (дата обращения: 16.05.2026).
3. Wolf T. et al. Transformers: State-of-the-Art Natural Language Processing // Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations. 2020. P. 38–45. URL: <https://aclanthology.org/2020.emnlp-demos.6/>
4. Maas A. L., Daly R. E., Pham P. T., Huang D., Ng A. Y., Potts C. Learning Word Vectors for Sentiment Analysis // Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics: Human Language Technologies. 2011. P. 142–150.
5. Vaswani A., Shazeer N., Parmar N., Uszkoreit J., Jones L., Gomez A. N., Kaiser L., Polosukhin I. Attention is all you need // Advances in neural information processing systems. 2017. Vol. 30. P. 5998–6008. URL: <https://arxiv.org/abs/1706.03762>
6. Hinton G., Vinyals O., Dean J. Distilling the Knowledge in a Neural Network // NIPS Deep Learning and Representation Learning Workshop. 2015. URL: <https://arxiv.org/abs/1503.02531>

ПРИЛОЖЕНИЕ

Ниже приведен листинг программного кода для проведения эксперимента в среде Google Colab.

```
# Установка зависимостей (выполняется в терминале или ячейке
Colab: !pip install transformers datasets evaluate scikit-
learn)
import torch
import time
import numpy as np
from datasets import load_dataset
from transformers import AutoTokenizer,
AutoModelForSequenceClassification
from transformers import TrainingArguments, Trainer
from sklearn.metrics import accuracy_score, f1_score,
precision_score, recall_score

# Фиксация случайных зерен для воспроизводимости
RANDOM_STATE = 42
torch.manual_seed(RANDOM_STATE)
np.random.seed(RANDOM_STATE)

# Функция расчета метрик
def compute_metrics(eval_pred):
    logits, labels = eval_pred
    predictions = np.argmax(logits, axis=-1)
    return {
        'accuracy': accuracy_score(labels, predictions),
        'f1': f1_score(labels, predictions, average='binary'),
        'precision': precision_score(labels, predictions,
average='binary'),
        'recall': recall_score(labels, predictions,
average='binary')
    }

def run_experiment(model_name, freeze_encoder=False):
    print(f"\n[{'FROZEN ' if freeze_encoder else ''}EXPERIMENT]:
{model_name}")

    # Загрузка токенизатора и датасета
    tokenizer = AutoTokenizer.from_pretrained(model_name)
    dataset = load_dataset("stanfordnlp/imdb")

    # Берем малую выборку для скорости (2000 train, 500 test)
    small_train_dataset =
dataset["train"].shuffle(seed=RANDOM_STATE).select(range(2000))
    small_test_dataset =
dataset["test"].shuffle(seed=RANDOM_STATE).select(range(500))

    def tokenize_function(examples):
        return tokenizer(examples["text"],
padding="max_length", truncation=True, max_length=256)
```

```

        tokenized_train =
small_train_dataset.map(tokenize_function, batched=True)
        tokenized_test = small_test_dataset.map(tokenize_function,
batched=True)

        # Инициализация модели
        model =
AutoModelForSequenceClassification.from_pretrained(model_name,
num_labels=2)

        # УЛУЧШЕНИЕ: Заморозка весов энкодера
        if freeze_encoder:
            if 'distilbert' in model_name:
                for param in model.distilbert.parameters():
                    param.requires_grad = False
            elif 'bert' in model_name:
                for param in model.bert.parameters():
                    param.requires_grad = False

        # Использование eval_strategy вместо устаревшего
evaluation_strategy
        training_args = TrainingArguments(
            output_dir="./results",
            learning_rate=2e-5,
            per_device_train_batch_size=16,
            per_device_eval_batch_size=16,
            num_train_epochs=3,
            weight_decay=0.01,
            eval_strategy="epoch",
            save_strategy="no",
            report_to="none"
        )

        trainer = Trainer(
            model=model,
            args=training_args,
            train_dataset=tokenized_train,
            eval_dataset=tokenized_test,
            compute_metrics=compute_metrics,
        )

        # Замер времени обучения
        start_time = time.time()
        trainer.train()
        train_time = time.time() - start_time

        # Замер времени инференса (тестирования)
        start_time = time.time()
        eval_results = trainer.evaluate()
        infer_time = time.time() - start_time

        print(f"Время обучения: {train_time:.1f} сек")

```

```

    print(f"Время инференса (500 шт): {infer_time:.1f} сек")
    print(f"Accuracy: {eval_results['eval_accuracy']:.4f}, F1: {eval_results['eval_f1']:.4f}")

    return eval_results

def main():
    print("Запуск пайплайна экспериментов...")
    # 1. Базовый BERT
    res_bert = run_experiment("bert-base-uncased",
freeze_encoder=False)

    # 2. Дистиллированный BERT
    res_distil = run_experiment("distilbert-base-uncased",
freeze_encoder=False)

    # 3. Улучшение: Замороженный DistilBERT
    res_frozen = run_experiment("distilbert-base-uncased",
freeze_encoder=True)

if __name__ == '__main__':
    main()

```