



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное
учреждение
высшего образования «Московский государственный технический
университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

ОТЧЕТ
ПО ЛАБОРАТОРНОЙ РАБОТЕ № 1
По дисциплине «Методы машинного обучения»
на тему «Обработка признаков, часть 1»

Студент ИУ5-22М
(Группа)

(Подпись, дата)

П. В. Бумагин
(И.О.Фамилия)

Преподаватель

(Подпись, дата)

Ю. Е. Гапанюк
(И.О.Фамилия)

Лабораторная работа №1

Тема: Обработка признаков (часть 1)

- **Выполнил:** Бумагин П. В.
- **Группа:** ИУ5-22М
- **Преподаватель:** Гапанюк Ю. Е.

1. Описание задания

Цель работы: Изучение продвинутых способов предварительной обработки данных для дальнейшего формирования моделей машинного обучения.

Задачи:

1. Выбрать набор данных (датасет), содержащий категориальные и числовые признаки и пропуски в данных.
2. Устранить пропуски в данных (для числовых и категориальных признаков).
3. Выполнить кодирование категориальных признаков.
4. Выполнить нормализацию числовых признаков.

```
In [1]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import OneHotEncoder, LabelEncoder, PowerTransformer

# Настройка стиля графиков
sns.set_theme(style="whitegrid")

# Загружаем датасет о пингвинах архипелага Палмер
df = sns.load_dataset('penguins')

print(f"Размерность исходного датасета: {df.shape}")
print("\nПервые 5 строк датасета:")
print(df.head())
```

Размерность исходного датасета: (344, 7)

Первые 5 строк датасета:

	species	island	bill_length_mm	bill_depth_mm	flipper_length_mm
0	Adelie	Torgersen	39.1	18.7	18
1	Adelie	Torgersen	39.5	17.4	18
2	Adelie	Torgersen	40.3	18.0	19
3	Adelie	Torgersen	NaN	NaN	NaN
4	Adelie	Torgersen	36.7	19.3	19

	body_mass_g	sex
0	3750.0	Male
1	3800.0	Female
2	3250.0	Female
3	NaN	NaN
4	3450.0	Female

Анализ пропусков в данных


Определим, в каких колонках нашего датасета присутствуют пропущенные значения (NaN).

```
In [2]: # Вычисляем количество пропусков для каждого признака
missing_info = df.isnull().sum()
print("Количество пропусков по колонкам:")
print(missing_info[missing_info > 0])

# Визуализируем пропуски с помощью тепловой карты
plt.figure(figsize=(8, 5))
sns.heatmap(df.isnull(), cbar=False, yticklabels=False, cmap='virid')
plt.title('Тепловая карта пропусков в данных')
plt.show()
```

Количество пропусков по колонкам:

bill_length_mm	2
bill_depth_mm	2
flipper_length_mm	2
body_mass_g	2
sex	11
dtype:	int64



Решение задачи 1: Устранение пропусков в данных

Заполнение пропусков в числовых признаках

Для числовых признаков (например, `bill_length_mm` — длина клюва) мы применим заполнение медианой, так как медиана устойчива к возможным выбросам.

```
In [3]: # Создаем импутер для заполнения медианой
num_imputer = SimpleImputer(strategy='median')

# Колонки с числовыми пропусками
num_cols = ['bill_length_mm', 'bill_depth_mm', 'flipper_length_mm',

# Заполняем пропуски
df[num_cols] = num_imputer.fit_transform(df[num_cols])

print("Число пропусков в числовых признаках после импутации:")
print(df[num_cols].isnull().sum())
```

Число пропусков в числовых признаках после импутации:

```
bill_length_mm      0
bill_depth_mm       0
flipper_length_mm   0
body_mass_g         0
dtype: int64
```

Заполнение пропусков в категориальных признаках

У нас есть пропуски в категориальной колонке `sex` (пол пингвина).
Заполним их наиболее часто встречающимся значением (модой).

```
In [4]: # Создаем импутер для заполнения наиболее частым значением (модой)
cat_imputer = SimpleImputer(strategy='most_frequent')

# Заполняем пропуски в колонке 'sex'
df[['sex']] = cat_imputer.fit_transform(df[['sex']])

print("Общее число пропусков в датасете после обработки:")
print(df.isnull().sum())
```

Общее число пропусков в датасете после обработки:

```
species      0
island        0
bill_length_mm  0
bill_depth_mm  0
flipper_length_mm  0
body_mass_g    0
sex           0
dtype: int64
```

Решение задачи 2: Кодирование категориальных признаков

Для того чтобы модели машинного обучения могли работать с текстовыми категориями, их нужно перевести в числовой вид. Применим два популярных метода кодирования:

1. **One-Hot Encoding (OHE):** Подходит для номинальных признаков без строгого порядка (например, признак `island` — остров).
2. **Label Encoding:** Кодирование целыми числами (подходит для бинарных признаков, таких как `sex`).

```
In [5]: # 1. Применяем Label Encoding к бинарному признаку 'sex'
le = LabelEncoder()
df['sex_encoded'] = le.fit_transform(df['sex'])
print("Соответствие классов после Label Encoding (sex):")
for index, class_name in enumerate(le.classes_):
    print(f" {class_name} -> {index}")

# 2. Применяем One-Hot Encoding к номинальному признаку 'island'
ohe = OneHotEncoder(sparse_output=False, drop='first') # drop='first'
island_ohe = ohe.fit_transform(df[['island']])

# Создаем новые колонки на основе категорий
ohe_cols = [f"island_{cat}" for cat in ohe.categories_[0][1:]]
df_ohe = pd.DataFrame(island_ohe, columns=ohe_cols)

# Объединяем полученные колонки с основным датафреймом
```

```
df = pd.concat([df, df_ohe], axis=1)

print("\nРезультат кодирования признаков (первые 5 строк):")
print(df[['island'] + ohe_cols + ['sex', 'sex_encoded']].head())
```

Соответствие классов после Label Encoding (sex):

Female -> 0
Male -> 1

Результат кодирования признаков (первые 5 строк):

	island	island_Dream	island_Torgersen	sex	sex_encoded
0	Torgersen	0.0	1.0	Male	1
1	Torgersen	0.0	1.0	Female	0
2	Torgersen	0.0	1.0	Female	0
3	Torgersen	0.0	1.0	Male	1
4	Torgersen	0.0	1.0	Female	0

Решение задачи 3: Нормализация числовых признаков

Нормализация применяется для того, чтобы привести распределение числового признака к виду, максимально близкому к нормальному (гауссовскому) распределению.

Будем нормализовать признак `body_mass_g` (масса тела пингвина).

Применим два популярных преобразования:

1. **Логарифмическое преобразование** (*np.log*).
2. **Преобразование Йео-Джонсона (Yeo-Johnson)** — мощный степенной метод, оптимизирующий параметры нормальности автоматически.

```
In [6]: # 1. Логарифмирование
df['body_mass_log'] = np.log(df['body_mass_g'])

# 2. Преобразование Йео-Джонсона (используем PowerTransformer)
pt = PowerTransformer(method='yeo-johnson')
df['body_mass_yeo'] = pt.fit_transform(df[['body_mass_g']])

print("Описательные статистики признака до и после нормализации:")
print(df[['body_mass_g', 'body_mass_log', 'body_mass_yeo']].describe())
```

Описательные статистики признака до и после нормализации:

	body_mass_g	body_mass_log	body_mass_yeo
count	344.000000	344.000000	3.440000e+02
mean	4200.872093	8.325386	9.679079e-14
std	799.696532	0.187460	1.001457e+00
min	2700.000000	7.901007	-2.474441e+00
25%	3550.000000	8.174703	-7.933585e-01
50%	4050.000000	8.306472	-5.790896e-02
75%	4750.000000	8.465900	7.731492e-01
max	6300.000000	8.748305	2.100795e+00

```
In [7]: # Построим графики распределений до и после преобразований
```


```
fig, axes = plt.subplots(1, 3, figsize=(18, 5))

# Исходное распределение массы тела
sns.histplot(df['body_mass_g'], bins=20, kde=True, ax=axes[0], color='blue')
axes[0].set_title('Исходный признак (body_mass_g)', fontsize=12)
axes[0].set_xlabel('Масса (г)')

# После логарифмирования
sns.histplot(df['body_mass_log'], bins=20, kde=True, ax=axes[1], color='orange')
axes[1].set_title('После логарифмирования (body_mass_log)', fontsize=12)
axes[1].set_xlabel('log(Масса)')

# После преобразования Йео-Джонсона
sns.histplot(df['body_mass_yeo'], bins=20, kde=True, ax=axes[2], color='green')
axes[2].set_title('После Йео-Джонсона (body_mass_yeo)', fontsize=12)
axes[2].set_xlabel('Масштабированная масса')

plt.tight_layout()
plt.show()
```



Выводы по лабораторной работе

В результате выполнения лабораторной работы были изучены и применены на практике методы предобработки данных на примере датасета «Penguins»:

- Обработка пропусков:** С помощью класса `SimpleImputer` устранены пропуски в данных. Числовые признаки заполнены медианными значениями (что защищает от влияния выбросов), а категориальный признак пола (`sex`) заполнен модой (наиболее часто встречающимся значением).
- Кодирование категориальных признаков:** Выполнено кодирование признаков с использованием `LabelEncoder` (для бинарного признака пола) и `OneHotEncoder` (для номинального признака острова). Это позволило представить качественные данные в виде векторов чисел, пригодных для обучения ML-моделей.
- Нормализация признаков:** Было исследовано влияние логарифмического преобразования и метода Йео-Джонсона на числовой признак массы тела. Преобразование Йео-Джонсона успешно центрировало распределение и приблизило его форму к стандартной нормальной кривой.

