

Рубежный контроль № 1

По дисциплине:

Методы машинного обучения в АСОИУ

Выполнил:

Сутдент гр. ИУ5-22М

Бумагин П. В.

Вариант 1

Задание

Задача № 1

Для набора данных проведите кодирование одного (произвольного) категориального признака с использованием метода "count (frequency) encoding".

Задача № 21

Для набора данных проведите масштабирование данных для одного (произвольного) числового признака с использованием масштабирования по медиане.

Дополнительное задание:

для произвольной колонки данных построить гистограмму

Загрузим данные датасета

```
In [1]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import RobustScaler

# Настройка стиля графиков
sns.set_theme(style="whitegrid")

# Загружаем датасет напрямую по URL-адресу из репозитория seaborn-d
url = "https://raw.githubusercontent.com/mwaskom/seaborn-data/master"
```

```
df = pd.read_csv(url)

print(f"Размерность набора данных: {df.shape}")
print("\nПервые 5 строк датасета:")
print(df.head())
```

Размерность набора данных: (244, 7)

Первые 5 строк датасета:

	total_bill	tip	sex	smoker	day	time	size
0	16.99	1.01	Female	No	Sun	Dinner	2
1	10.34	1.66	Male	No	Sun	Dinner	3
2	21.01	3.50	Male	No	Sun	Dinner	3
3	23.68	3.31	Male	No	Sun	Dinner	2
4	24.59	3.61	Female	No	Sun	Dinner	4

Описание набора данных «Tips» (Чаевые)

Для выполнения работы выбран классический набор данных «**Tips**», который часто используется в качестве демонстрационного в библиотеке визуализации данных **Seaborn**. Исторически эти данные были собраны официантом одного из ресторанов США в течение нескольких месяцев работы.

1. Основные характеристики датасета:

- **Количество записей (строк):** 244
- **Количество признаков (столбцов):** 7
- **Наличие пропусков:** Данные полностью заполнены (пропуски отсутствуют).

2. Структура признаков:

Имя признака	Тип данных	Описание	Тип шкалы
total_bill	Вещественный (float)	Общая сумма счета за заказ в долларах США	Количественный непрерывный
tip	Вещественный (float)	Размер чаевых в долларах США	Количественный непрерывный
sex	Категориальный (binary)	Пол клиента, оплатившего счет (Male / Female)	Качественный номинальный
smoker	Категориальный (binary)	Наличие курильщиков в компании клиентов (Yes / No)	Качественный номинальный
day	Категориальный (4 градации)	День недели (Thur , Fri , Sat , Sun)	Качественный номинальный
time	Категориальный	Время приема пищи (Lunch — обед /	Качественный

	(binary)	Dinner — ужин	номинальный
size	Целочисленный (int)	Размер компании клиентов (количество человек за столом)	Количественный дискретный

3. Обоснование выбора признаков для выполнения задач:

- **Для Задачи №1 (Count / Frequency Encoding):** Признак `day` (день недели) является категориальным и принимает 4 различных значения. Он хорошо подходит для демонстрации частотного кодирования, так как разные дни недели встречаются в выборке с разной регулярностью (например, суббота и воскресенье посещаются чаще, чем четверг и пятница).
- **Для Задачи №21 (Масштабирование по медиане):** Признак `total_bill` (общий счет) представляет собой непрерывную числовую величину. Он имеет выраженное смещение вправо (асимметрию) и несколько крупных единичных значений (счетов более \$40), которые можно классифицировать как выбросы. Это позволяет наглядно продемонстрировать преимущества масштабирования по медиане и межквартильному размаху (Robust Scaling), которое, в отличие от MinMaxScaler или StandardScaler, не сжимает основную массу данных в узкий диапазон под влиянием аномальных значений.


Построим гистограмму для числового признака `total_bill` (общий счет), чтобы визуализировать форму исходного распределения расходов посетителей.

```
In [2]: plt.figure(figsize=(10, 5))
sns.histplot(df['total_bill'], bins=20, kde=True, color='teal')

# Рассчитаем медиану и среднее
median_bill = df['total_bill'].median()
mean_bill = df['total_bill'].mean()

plt.axvline(median_bill, color='red', linestyle='--', linewidth=2,
plt.axvline(mean_bill, color='orange', linestyle='-', linewidth=2,

plt.title('Гистограмма распределения признака "total_bill" (Общий с
plt.xlabel('Сумма счета ($)')
plt.ylabel('Количество заказов')
plt.legend()
plt.show()
```



Задача №1. Кодирование категориальных признаков методом Count (frequency) encoding

Описание метода: При кодировании подсчетами (Count Encoding) категориальное значение заменяется на абсолютное количество его появлений в выборке. При частотном кодировании (Frequency Encoding) значение заменяется на относительную долю (частоту) в выборке. Применим данный метод к признаку `day` (день недели).

```
In [3]: # Расчет абсолютных частот встречаемости дней недели
count_map = df['day'].value_counts().to_dict()
print("Абсолютные частоты категорий (Count Encoding):")
for day, count in count_map.items():
    print(f" {day}: {count}")

# Расчет относительных частот (долей)
freq_map = df['day'].value_counts(normalize=True).to_dict()
print("\nОтносительные частоты категорий (Frequency Encoding):")
for day, freq in freq_map.items():
    print(f" {day}: {freq:.4f} ({freq*100:.2f}%)")

# Добавление закодированных признаков в исходную таблицу
df['day_count'] = df['day'].map(count_map)
df['day_freq'] = df['day'].map(freq_map)

print("\nРезультаты кодирования признака 'day' (первые 10 строк):")
print(df[['day', 'day_count', 'day_freq']].head(10))
```

Абсолютные частоты категорий (Count Encoding):

Sat: 87
Sun: 76
Thur: 62
Fri: 19

Относительные частоты категорий (Frequency Encoding):

Sat: 0.3566 (35.66%)
Sun: 0.3115 (31.15%)
Thur: 0.2541 (25.41%)
Fri: 0.0779 (7.79%)

Результаты кодирования признака 'day' (первые 10 строк):

	day	day_count	day_freq
0	Sun	76	0.311475
1	Sun	76	0.311475
2	Sun	76	0.311475
3	Sun	76	0.311475
4	Sun	76	0.311475
5	Sun	76	0.311475
6	Sun	76	0.311475
7	Sun	76	0.311475
8	Sun	76	0.311475
9	Sun	76	0.311475

Задача №21. Масштабирование признаков по медиане

Описание метода: Масштабирование по медиане и межквартильному размаху (IQR) используется для приведения числовых признаков к единому масштабу без сильного искажения под влиянием аномально больших или малых значений (выбросов).

Формула:

$$X'_{scaled} = \frac{X - \text{median}(X)}{Q_3(X) - Q_1(X)}$$

где:

- $Q_1(X)$ — первый квартиль (25-й процентиль),
- $Q_3(X)$ — третий квартиль (75-й процентиль),
- $Q_3(X) - Q_1(X)$ — межквартильный размах (IQR).

Выполним масштабирование признака `total_bill` вручную по формуле и с помощью библиотечного класса `RobustScaler`.

```
In [4]: # Ручной расчет масштабирования по медиане
median_val = df['total_bill'].median()
q25 = df['total_bill'].quantile(0.25)
q75 = df['total_bill'].quantile(0.75)
iqr_val = q75 - q25
```

```

df['total_bill_scaled_manual'] = (df['total_bill'] - median_val) /

# Использование RobustScaler из sklearn
scaler = RobustScaler()
df['total_bill_scaled_sklearn'] = scaler.fit_transform(df[['total_b

print(f"Статистики признака 'total_bill':")
print(f"  Медиана: {median_val:.3f}")
print(f"  Q1 (25%): {q25:.3f}")
print(f"  Q3 (75%): {q75:.3f}")
print(f"  IQR (межквартильный размах): {iqr_val:.3f}")

print("\nСравнение ручного расчета и RobustScaler (первые 5 строк):")
print(df[['total_bill', 'total_bill_scaled_manual', 'total_bill_sca

print("\nОписательная статистика до и после масштабирования:")
stats_comparison = df[['total_bill', 'total_bill_scaled_sklearn']].
print(stats_comparison.loc[['mean', 'std', 'min', '50%', 'max']])

```

Статистики признака 'total_bill':

```

Медиана: 17.795
Q1 (25%): 13.348
Q3 (75%): 24.127
IQR (межквартильный размах): 10.780

```

Сравнение ручного расчета и RobustScaler (первые 5 строк):

	total_bill	total_bill_scaled_manual	total_bill_scaled_sklearn
0	16.99	-0.074675	-0.074675
1	10.34	-0.691558	-0.691558
2	21.01	0.298237	0.298237
3	23.68	0.545918	0.545918
4	24.59	0.630334	0.630334

Описательная статистика до и после масштабирования:

	total_bill	total_bill_scaled_sklearn
mean	19.785943	1.846886e-01
std	8.902412	8.258267e-01
min	3.070000	-1.365955e+00
50%	17.795000	-1.647987e-16
max	50.810000	3.062616e+00

Сравнение распределения до и после масштабирования

Построим гистограммы для наглядного сравнения шкал до и после масштабирования.

```

In [5]: fig, axes = plt.subplots(1, 2, figsize=(15, 5))

# Исходный признак
sns.histplot(df['total_bill'], bins=20, kde=True, ax=axes[0], color
axes[0].set_title('Исходный признак "total_bill"')
axes[0].set_xlabel('Сумма счета ($)')

```


```

axes[0].axvline(median_val, color='red', linestyle='--', label=f'Me
axes[0].legend()

# После RobustScaler
sns.histplot(df['total_bill_scaled_sklearn'], bins=20, kde=True, ax
axes[1].set_title('После Robust Scaling')
axes[1].set_xlabel('Масштабированное значение')
axes[1].axvline(0.0, color='red', linestyle='--', label='Медиана: 0
axes[1].legend()

plt.tight_layout()
plt.show()

```



Вывод

В ходе выполнения рубежного контроля №1 были решены следующие задачи на примере датасета «Tips»:

1. Гистограмма распределения (требование ИУ5-22М):

Построенный график для признака `total_bill` демонстрирует асимметричное правостороннее распределение. Наличие длинного правого хвоста указывает на присутствие более дорогих заказов (выбросов), существенно превышающих медианное значение (17.79\$).

2. Count (frequency) encoding: Категориальный признак `day` успешно закодирован. Были получены как абсолютные частоты (например, суббота встречается 87 раз), так и относительные доли (~35.66% заказов приходится на субботу). Такое кодирование позволяет передать модели информацию о плотности категорий без искусственного навязывания порядка.

3. Масштабирование по медиане: Применение масштабирования (как вручную, так и через `RobustScaler`) привело значения `total_bill` к единому масштабу, центрировав распределение ровно на уровне 0.0 по медиане. Поскольку разброс оценивался по межквартильному размаху (IQR), влияние единичных крупных счетов на итоговый диапазон масштабирования было успешно минимизировано.